

KBO 직관 안내 챗봇 — 데이터 파트 정리 (9/7)

지금까지 데이터 쪽에서 뭘 했고, 폴더는 왜 이렇게 나뉘었고, 앞으로 뭘 정해야 하는지 한 번에 모아봤습니다. 회의 때 이 문서 하나만 보면 됩니다.

1. 지금까지 진행 상황

영역	상태	비고
팀 순위 (KBO standing)	완료, 자동 수집	TVING 내부 API로 매일 수집, 이력까지 누적
경기 일정 (3~10월)	완료, 자동 수집	스코어 포함, 포스트시즌은 참가팀 미정이라 별도 TBD 파일
예매정책	완료	yagu.today 원본 크롤링 → 자연어 문장을 구조화된 표로 변환 완료
반입물품 규정	9개 구단 중 7개 확인	KT, NC 두 곳만 세부 항목 확인 필요
재입장 규정	부분 확인	고척은 확인, 나머지 구단은 검증 메모만 있고 확정 안 됨
구장 내 편의시설 (흡연실/수유실/화장실)	대부분 미확인	공식 자료에 거의 없어서 직접 조사해야 함
구장 주변 먹거리 (외부)	1차 대조 완료	기존 자료 vs 카카오 API 신규 수집본 대조 → 신규 후보 18건 발견, 상세는 4번 참고
폴더/스크립트 정리	오늘 완료	아래 3번 참고

2. 폴더 구조

`baseball_data_organized` 폴더 하나로 통일했습니다. 기준은 간단합니다 — **스크립트랑 데이터를 분리하고, 데이터는 “우리가 손댔는지 아닌지”로 나눈다.**

폴더	뭐가 들어가나	특징
<code>data/raw/</code>	팀원이 준 원본 그대로	어떤 스크립트도 이 폴더를 자동으로 건드리지 않음

폴더	뭐가 들어가나	특징
<code>data/preprocessed/</code>	크롤링·전처리 스크립트를 돌리면 나오는 결과물	실행할 때마다 새로 갱신됨 (덮어쓰기 있음)
<code>crawling/</code>	API·웹에서 데이터를 직접 가져오는 스크립트	결과 파일은 안 두고 코드만
<code>preprocessing/</code>	raw나 크롤링 결과를 가공/구조화하는 스크립트	마찬가지로 코드만
<code>docs/</code>	사람이 읽는 문서, 가이드, 리서치 엑셀	이 문서도 여기 들어감

헛갈리기 쉬운 부분: `kbo_standing.csv` 처럼 실행할 때마다 새로 만들어지는 파일은 겹보기엔 “원본”처럼 보여도 `preprocessed` 로 분류합니다. raw는 어디까지나 “팀이 준 파일 그대로”만 뜻합니다.

폴더명은 `crawling` / `preprocessing` 으로 나눈 채 유지하기로 확정했습니다. “그냥 하나로 합쳐서 scripts로 부를까”도 고민했었는데, 가져오는 것(crawling)과 가공하는 것(preprocessing)의 역할이 달라서 나눠두는 게 나중에 찾기 편할 것 같아 그대로 갑니다. 참고로 스크립트들은 자기 위치 기준 상대경로를 쓰기 때문에, 나중에 폴더명을 바꾸더라도 코드가 깨지지 않습니다.

참고로 이 폴더는 아직 팀 전체에 공유 전이고, 제가(형준) 개인적으로 정리하던 폴더입니다. 예전 `baseball_data` (한글 폴더명) 쪽에만 있는 자료가 있는지 한 번 더 확인한 다음에 팀에 공유할 예정입니다.

실제 폴더 트리 (9/7 기준)

```
baseball_data_organized/
├── .env
├── README.md
├── my_venv/
├──
├── crawling/
│   ├── kbo_standing.py
│   ├── kbo_schedule.py
│   ├── collect_kakao_places.py
│   ├── README.md
│   └── requirements.txt
├──
├── preprocessing/
│   ├── parse_ticket_policy.py
│   ├── kbo_schedule_postseason_placeholder.py
│   ├── team_stadium_map.py
│   └── README.md
├──
├── data/
│   ├── raw/
│   │   ├── 구장정보.xlsx
│   │   ├── 구장먹거리,컨텐츠.xlsx
│   │   ├── backlog 보충.xlsx
│   │   ├── 재입장 규정.비공식.txt
│   │   ├── kbo_schedule.csv
│   │   ├── kbo_ticket_policy.csv
│   │   ├── team_stadium_code_map.csv
│   │   └── 시트가 뭘 의미하는지.xlsx
│   ├──
│   ├── preprocessed/
│   │   ├── kbo_standing.csv
│   │   ├── kbo_standing_history.csv
│   │   ├── kbo_schedule_full.csv
│   │   ├── kbo_schedule_postseason_tbd.csv
│   │   ├── kbo_ticket_policy_structured.csv
│   │   ├── stadium_coordinates.csv
│   │   └── external_places.csv
│   ├──
│   └── docs/
│       ├── 기초규칙_요약본.md
│       ├── 반입물품_구단별정리.md
│       ├── 재입장규정_검증메모.md
│       ├── 원정응원가이드.xlsx
│       ├── 환경설정_my_venv.md
│       ├── 진행상황_리포트_20260907.pdf
│       ├── 크롤링_전처리_실행가이드_20260907.pdf
│       └── 데이터파트_종합정리_20260907.pdf
```

폴더별로 짧게 설명하면: `.env` 는 카카오/티맵/네이버 등 API 키가 들어있어 git에 올리면 안 되는 파일이고, `my_venv` 는 파이썬 가상환경이라 마찬가지로 git 제외 대상입니다. `crawling` 은 API·웹에서 데이터를 “가져오기만” 하는 스크립트, `preprocessing` 은 가져온 데이터를 가공·구조화하는 스크립트, `data/raw` 는 팀원이 준 원본(절대 안 건드림), `data/preprocessed` 는 스크립트를 돌리면 나오는 결과물(실행할 때마다 갱신), `docs` 는 사람이 읽는 문서입니다.

data/raw/ 파일별 — 어떤 데이터인지

파일	어떤 데이터인지
구장정보.xlsx	9개 구장·10개 팀의 좌석구역, 교통편, 반입규정, 편의 시설, 티켓가격 등 구단 공식 정보. 시트가 12개나 되고 (좌석구역 192건, 티켓가격 740건 등) 각 값마다 출처와 확인상태(CONFIRMED/PARTIAL/OPEN)까지 달려있는 제일 두꺼운 원본 파일
구장먹거리,컨텐츠.xlsx	구장 “내부” 매점·먹거리 284건 + 부가 콘텐츠(포토존 등) 68건. 외부 맛집은 여기 없고, 그건 카카오 API로 따로 수집(아래 external_places.csv)
backlog 보충.xlsx	위 두 파일에서 “아직 못 채운 항목”을 정리한 보충 리스트 — 구조적으로 원래 공개 안 되는 정보 (STRUCTURAL_GAP)인지, 다른 공공데이터로 채울 수 있는지(RESOLVABLE)인지 등으로 분류해둠
재입장 규정.비공식.txt	9개 구단 재입장 규정을 블로그/SNS 등에서 비공식으로 조사한 메모. 공식 자료가 아니라서 확정 전 검증 필요
시트가 뭘 의미하는지.xlsx	위 엑셀들 안의 시트/컬럼 이름이 각각 뭘 뜻하는지 설명해주는 용어 설명서 (헛갈릴 때 이거 먼저 확인)
kbo_schedule.csv	팀원이 직접 크롤링한 9월 한 달치 경기 일정 원본
kbo_ticket_policy.csv	yagu.today에서 크롤링한 예매정책 원본. “선착순 예매는 경기 3일 전부터” 같은 문장 형태 그대로임
team_stadium_code_map.csv	“두산”/“Doosan”/“OB”처럼 제각각인 팀 이름을 표준 코드(DOOSAN 등)로 통일하는 기준표. 구장정보.xlsx를 기준으로 만들

data/preprocessed/ 파일별 — 어떤 데이터인지

파일	어떤 데이터인지
kbo_standing.csv	오늘 기준 팀 순위 최신 스냅샷 (실행할 때마다 덮어써짐)
kbo_standing_history.csv	위 순위를 날짜별로 계속 쌓아놓은 이력 (순위 변화 흐름을 보려면 이 파일)
kbo_schedule_full.csv	kbo_schedule.csv를 3~10월 시즌 전체로 확장하고 스코어까지 채운 버전
kbo_schedule_postseason_tbd.csv	포스트시즌 일정 — 아직 진출팀이 안 정해져서 팀명 자리가 TBD로 비어있는 placeholder

파일	어떤 데이터인지
kbo_ticket_policy_structured.csv	kbo_ticket_policy.csv의 문장을 날짜/시간/대상 같은 컬럼으로 쪼갠 구조화 버전
stadium_coordinates.csv	9개 구장 주소를 카카오 API로 위도·경도로 변환한 좌표표
external_places.csv	각 구장 반경 1~1.5km 안의 음식점·카페·관광명소를 카카오 API로 수집한 것 (867건, 구단 공식 아님 — THIRD_PARTY_API)

오늘 가지치기(정리)한 부분만 짚으면 이렇습니다. 가장 큰 원칙은 두 가지입니다. 스크립트(코드)와 데이터를 분리하고, 데이터는 다시 “우리가 손댔는지 아닌지”로 나눠서 raw(원본, 수정 금지)와 preprocessed(스크립트 결과, 매번 갱신)로 갈랐습니다.

이전엔 `_crawler` 라는 이름이 붙은 파일들이 있었는데, 실제로는 웹을 긁는 크롤링이 아니라 TVING 내부 API를 호출하는 방식이라 이름이 실제 동작과 안 맞았습니다. 그래서 `kbo_standing_crawler.py`, `kbo_schedule_full_crawler.py` 두 개를 각각 `kbo_standing.py`, `kbo_schedule.py` 로 이름만 바꾸고 예전 파일은 삭제했습니다. 로직은 손대지 않았습니다. 카카오 API 스크립트 (`collect_kakao_places.py`)는 `.env` 자동 로딩 버그를 고쳐서 오늘 정상 실행 확인했고, `stadium_coordinates.csv` / `external_places.csv` 도 오늘 새로 생성됐습니다. 이미 완전히 대체돼서 안 쓰는 `collect_standing_snapshot.py` 나 예전 폴더 구조 잔재(`raw_data/` 등)도 이번엔 다 정리해서 지금은 남아있는 게 없습니다.

3. 전처리 규칙

다들 각자 크롤링/수집한 데이터를 합칠 때 기준이 없으면 나중에 합치기 힘들어져서, 아래 규칙으로 통일하고 있습니다.

- **원본은 절대 안 건드린다.** 가공은 항상 복사본에서 하고 결과는 `preprocessed` 에 따로 저장.
- **팀 코드는 표준 코드로 통일.** “두산”/“Doosan”/“OB” 이런 식으로 제각각 쓰지 말고 `team_stadium_code_map.csv` 기준 코드(LG, DOOSAN, KIWOOM, SSG, KT, HANWHA, SAMSUNG, KIA, LOTTE, NC)로만 씀.
- **CSV는 utf-8-sig로 저장.** 엑셀에서 열었을 때 한글 깨지는 거 방지.
- **자연어 문장은 구조화된 컬럼으로 바꾼다.** 예매정책처럼 “선착순 예매는 경기 3일 전 오전 11시부터” 같은 문장 형태 원본은 그대로 두고, 별도 스크립트로 날짜/시간/대상 같은 컬럼으로 뽑아낸 버전을 추가로 만들.
- **출처를 반드시 표시한다 (status / evidence_type 태깅).**
 - status: `CONFIRMED` (확실) / `PARTIAL` (일부만 확인) / `OPEN` (미확인) / `RECHECK` (재확인 필요)
 - evidence_type: `OFFICIAL` (구단 공식) / `THIRD_PARTY_API` (카카오 등 제3자 API) / `UNOFFICIAL` (블로그·SNS 등 비공식 조사)
 - 이렇게 나눠두면 나중에 챗봇이 “이 정보는 공식이 아닐 수 있습니다” 같은 안내를 붙일 수 있음.

- **비공식으로 수집한 데이터는 공식 데이터랑 절대 안 섞는다.** 카카오 API로 수집한 외부 맛집 데이터가 대표적인 예 — 구단이 공식으로 밝힌 정보가 아니라서 `THIRD_PARTY_API` 로 명확히 구분.

4. 오늘 정리한 것 (폴더/스크립트)

- 크롤링 스크립트 이름에서 “crawler”를 뺐습니다. `kbo_standing_crawler.py` → `kbo_standing.py`, `kbo_schedule_full_crawler.py` → `kbo_schedule.py`.
 - 이유: 애네는 사실 웹페이지를 긁는 크롤링이 아니라 TVING 앱이 쓰는 내부 API를 그대로 호출하는 방식이라, “crawler”라는 이름이 실제 방식이랑 안 맞았습니다. 코드 로직은 전혀 안 건드렸고 이름만 바꿨습니다.
 - 예전 이름 파일은 삭제 완료.
- 카카오 API 스크립트(`collect_kakao_places.py`)가 `.env` 파일을 못 읽던 문제를 고쳤습니다.
 - 원인: 코드에 `.env` 파일을 실제로 읽어오는 부분이 아예 없었습니다. `.env` 에 키를 넣어봐도 파이썬이 자동으로 읽어주는 게 아니라서, 그동안은 항상 빈 키로 실행되고 있었습니다.
 - 조치: `python-dotenv` 라이브러리로 `.env` 파일을 읽어서 등록해주는 코드를 추가했습니다. `.env` 에 키만 넣어두면 코드는 더 안 건드려도 됩니다.
 - 오늘 직접 실행해서 `stadium_coordinates.csv`, `external_places.csv` 정상 생성 확인했습니다.
- 남은 일: `kbo_standing.py` 를 Windows 작업 스케줄러에 예약해줬다면, 등록된 작업의 “인수” 값을 새 파일명으로 바꿔야 합니다. (아직 안 함 — 스케줄 등록 안 했으면 넘어가도 됨)

5. 먹거리 데이터 대조 결과 (요약)

기존에 팀이 확보한 구장 내 먹거리 자료(284건)와 카카오 API로 새로 수집한 구장 반경 내 장소(27건)를 이름/주소 기준으로 대조했습니다.

분류	건수	의미
기존 자료와 중복	4건	이미 있는 데이터라 추가 불필요
신규 후보	18건	기존 자료에 없던 곳 — 추가할지 검토 필요
재확인 필요	5건	대전 쪽에서 “구장 내부”로 잘못 표시된 것으로 보임 — 카카오 수집 스크립트의 거리 기준 로직 점검 필요

자세한 항목별 리스트는 `먹거리_중복대조_결과.pdf` 에 정리되어 있습니다.

6. 팀에서 결정해야 할 것

- **TVING 내부 API 계속 쓸지 여부:** KBO는 공식 공개 API가 없어서, 어떤 방식을 택해도 완전히 “공식”은 아닙니다. 지금 쓰는 TVING 방식을 유지할지, 다른 방법을 찾을지 결정 필요.

- **먹거리 신규 후보 18건 반영 여부:** 검토해서 추가할지 말지 결정.
- **대전 재확인 필요 5건:** 원인(거리 기준 로직) 파악 후 처리 방향 결정.
- **비공식 조사 항목 담당 배분:** 좌석 뷰/지붕 여부(8개 구장), 재입장 규정(9개 팀 중 8개), KT·NC 반입물 품 세부, 편의시설 위치 등 — 누가 어디를 맡을지 정해야 함. 자세한 목록은 [비공식조사_필요항목_정리.pdf](#) 참고.
- **재입장 규정 검증:** 원 팀원에게 확인 요청 보낸 상태 — 답변 오면 반영.

7. 참고 문서 목록 (docs/ 폴더)

- [진행상황_리포트_20260907.pdf](#) — 6시 회의용 데이터 브리핑
- [비공식조사_필요항목_정리.pdf](#) — 직접 찾아야 할 항목 vs 안 찾아도 되는 항목
- [먹거리_중복대조_결과.pdf](#) — 먹거리 대조 상세 결과
- [크롤링_전처리_실행가이드_20260907.pdf](#) — 폴더 정리 및 일정 정리
- [환경설정_my_venv.md](#) — 가상환경 설치 가이드
- 이 문서 ([데이터파트_종합정리_20260907.pdf](#)) — 오늘 종합 정리