

KBO 직관 안내 챗봇 — 데이터 파이프라인 진행 상황

작성 기준일: 2026-09-07 · 대상: 2-3~2-9 데이터 항목 + 전처리 점검 + 로컬 자동화 + 폴더 재구성

개요

직관 코스 추천(경기 전 맛집 → 관람 → 경기 후 핫플레이스)이 핵심 리텐션 기능이라는 팀 방향에 맞춰, 9/6~9/7 동안 이 기능에 필요한 핵심 데이터의 수집 · 정리 · 전처리 완성도를 우선 점검했다. 온보딩/리텐션 관련 신규 기능 아이디어(선수 추천 등)는 팀 결정에 따라 이번 점검 범위에서 제외하고 나중에 미뤘다.

항목별 현황

항목	상태	비고
2-6 팀 순위 이력 누적	완료	크롤러 작성 + 경로 버그 수정 + 로컬 실제 실행 검증 완료. 자동화 등록만 남음.
2-5 시즌 일정 전체	완료	782경기(3/28~10/7, 스코어 포함) + 포스트시즌 TBD 4건. 경로 버그도 이번에 수정.
2-4 기초 규칙 요약본	완료	일반 상식(1부) + KBO 고유 규정(2부) + 직관 팁(3부) 보강 완료.
2-9 재입장 규정 검증	질문지 준비 완료	검증 질문 3가지 준비됨. 팀원 답변만 받으면 완료.
2-3 선수 데이터	최종 제외 결정	네이버 · 나무위키 · 구단 앱이 이미 잘 정리 → 차별화 가치 낮다고 판단.
2-7 원정 응원 가이드	사실상 완료	9개 구장 전부 PARTIAL, 7곳은 구역번호까지 확보. 잠실 · 대전만 방향만 확인.
전처리: 예매정책 CSV	완료	244/244행 구조화 파싱 성공 (정규식 3차 보완).
전처리: 팀코드 매핑 검증	완료	스크립트 3개 전수 대조, 전부 캐노니컬 매핑과 일치.
전처리: VS Code 실행환경	완료	requirements.txt + my_venv 가이드 + 실제 로컬 실행 검증 완료.

※ 2-8(좌석 후기 시드)은 팀 판단 보류 항목이라 이번 점검 범위에서 제외.

데이터 수집 상세 — 무엇을 어떻게 모았는가

2-6. 팀 순위 이력 (kbo_standing_history.csv)

목표: 기존 kbo_standing.csv는 특정 시점의 스냅샷 1개뿐이라 "최근 상승세" 같은 흐름 질문에 답할 수 없었다. 매일 스냅샷을 누적해 이력 테이블을 만드는 것이 목표.

방법: kbo_standing.csv의 source 컬럼에 남아있던 실제 API 주소(TVING 순위 API, 인증키 없이 GET 가능한 공개 JSON)를 그대로 활용했다. 직접 호출해 확인한 결과 원본 API 응답에는 기존 CSV 문장에 없던 winningStreak(연승/연패), battingAverage(팀 타율), earnedRunAverage(팀 방어율), recentGames(최근 10경기 성적) 필드까지 들어있어 이 4개를 보너스 컬럼으로 추가 수집했다. 팀원이 준 원본 kbo_standing_crawler.py는 그대로 두고, 이력 누적 로직만 추가하는 방식으로 확장했다(원본 파이프라인 호환성 유지).

결과: snapshot_date, team_code, rank, games, wins/losses/draws, win_rate, games_behind, winning_streak, batting_avg, era, recent_games 등 15개 컬럼으로 팀당 1행씩(총 10행) 매일 누적. 오늘 날짜 기록이 이미 있으면 중복 저장하지 않도록 안전장치를 넣어 하루 여러 번 실행해도 문제없다. 태깅: evidence_type=THIRD_PARTY_API, status=CONFIRMED.

2-5. 시즌 일정 전체 (kbo_schedule_full.csv + postseason_tbd)

목표: 기존 kbo_schedule.csv는 2026-09-05~09-30(22일치, 88행)만 있어 다음 달 이후 질문에 답을 못 했다. 이미 끝난 경기(스코어 포함)까지 포함한 시즌 전체로 확장하는 것이 목표.

방법: 팀원 크롤러는 "이번 달 캘린더에서 아직 안 지난 경기만" 가져오는 구조였다(9월 실행 시 9월치만 나오는 게 정상 동작, 버그 아님). 2026 KBO 정규시즌 개막일이 3월 28일이라는 것을 뉴스 기사로 확인한 뒤, TVING 일정 API를 3월~10월까지 전부 순회하도록 확장해서 개막일부터 오늘까지 지난 경기(스코어 포함) + 앞으로 남은 경기까지 한 번에 받아왔다. 3/12~3/24 시범경기과 7/11 올스타전(정식 팀코드가 아닌 나눔/드림 표기)은 자동으로 걸러서 제외했다.

결과: 정규시즌 782경기(스코어·구장·팀코드 포함)를 수집했고, 정규시즌 마지막 경기가 10월 7일이라는 것도 API 응답 패턴으로 확인했다(그 이후 날짜를 조회하면 10/7 데이터가 반복해서 나옴). 포스트시즌은 아직 참가팀이 정해지지 않았으므로, 나무위키에 이미 발표된 라운드별 날짜·대진 규칙(와일드카드전 10/9~10, 준PO 10/12~18, PO 10/20~26, 한국시리즈 10/28~11/5)만으로 4행을 TBD 상태로 만들었다 — team 컬럼은 전부 "TBD", evidence_type=DERIVED(발표된 규칙 기반), status_tag=OPEN으로 태깅해 리트리버가 확정 사실처럼 답하지 않도록 했다.

2-7. 원정 응원 가이드 (원정응원가이드.xlsx)

목표: "원정 팀 응원하려면 어디 앉아야 해요?"에 답할 수 있는 9개 구장별 원정석 위치 가이드. 팀에서도 애초에 공개 데이터가 거의 없을 것으로 예상했던 항목.

1차 조사: 나무위키 "원정석" 총론 문서에서 일반 원칙 확인 — KBO는 원정석을 공식 지정하지 않지만, 관례상 대부분 구장은 1루=홈/3루=원정이고 대구(삼성)·광주(KIA)만 반대(홈=3루/원정=1루)다. 이 원칙 위에 블로그·커뮤니티 정보를 찾아 4곳(문학·수원·대구·사직)은 구역 번호까지 확인했고, 나머지 5곳은 방향만 아는 상태로 남았다.

2차 조사: 팀원이 찾아준 myseatcheck.com을 계기로, 각 구장 자체의 나무위키 문서(총론이 아닌 개별 구장 문서)에서 "더그아웃 1루(홈)/3루(원정)" 같은 구장 자체 명시 정보를 확인했다. 창원은 sportstrends.co.kr 블로그에서 "원정 응원석 119~121블록"이라는 구체적 블록 번호까지 추가로 확보했다.

3차 조사: WebFetch는 자바스크립트를 실행하지 않아 디시인사이드·FM코리아 같은 SPA 페이지가 빈 화면으로 읽혔는데, 브라우저 렌더링 도구로 직접 열어 읽는 방식으로 우회했다. 광주는 FM코리아 실제 질문글에서 "1루 노란색 좌석, 109구역이 정면"이라는 답을 확보했고, 고척은 myseatcheck.com과 디시인사이드 공지에서 "3루 버건디석 113구역"을 확인했다. 대전은 디시인사이드에서 찾은 글이 2018년 이전 구 이글스파크 기준임을 실제로 열어봐서 걸러냈다(잘못된 정보를 쓸 뻔한 걸 직접 확인으로 방지).

구단 공식 채널 검증: 키움·KIA 공식 사이트를 직접 열어 확인한 결과, 공식 채널은 좌석을 가격/등급으로만 안내하고(VIP·버건디석·지정석 등) 홈/원정 구분이 아예 없었다 — "버건디석은 1루·3루에 각 50석씩 동일하게 있다"는 문구로 등급명이 홈/원정과 무관함을 재확인했다. 즉 이 데이터는 구조적으로 UNOFFICIAL 등급 이상으로 올라갈 수 없다는 결론.

결과: 9개 구장 전부 status=PARTIAL, evidence_type=UNOFFICIAL. 문학·수원·대구·사직·창원·광주·고척 7곳은 구역/블록 번호까지, 잠실·대전 2곳은 방향만 확보.

2-4. 기초 규칙 요약본 (기초규칙_요약본.md)

1부(일반 야구 상식)는 어떤 사이트도 베끼지 않고 초보자가 헛갈리는 포인트 위주로 새로 작성(이닝·아웃·스트라이크볼·안타종류·포지션·용어·FAQ). 2부(KBO 고유 규정)는 "기본 내용만 있다"는 피드백을 반영해 웹 검색으로 지명타자 제도, ABS(로봇심판, 2024년 세계 최초 도입), 피치클락(2026시즌 18/23초로 단축), 비디오 판독, 외국인 선수 규정, 연장전 규정을 조사해서 추가했다. 3부(직관 관람 팁)는 우천 시 노게임/콜드게임 기준, 파울볼 안전, 도착 타이밍 등 현장 실전 팁을 추가했다. 이후 분량이 많다는 피드백을 받아 표·짧은 불릿 위주로 다시 압축했다.

전처리 상세 — 어떻게 가공했는가

① 예매정책 CSV 구조화 (kbo_ticket_policy.csv → kbo_ticket_policy_structured.csv)

문제: 244행 전부가 "[선예매] 두산 선예매 (베어스클럽) 9월 5일 토요일 오전 10시 (9/12 NC전) NC vs 두산 (9/12) 오픈: ... 예매처: ..." 같은 자연어 한 문장에 값이 다 들어있는 형태라, MySQL 정형 테이블에 바로 적재할 수 없었다.

진행 과정: 정규식으로 정책유형(선예매/일반), 정책명, 하위구분(베어스클럽 등), 오픈 날짜·요일·시간, 상대전 날짜, 원정/홈 팀명과 표준 team_code, 최대 구매 매수, 예매처+조건 텍스트까지 캡처 그룹으로 분리하는 파서를 작성했다. 1차 시도에서는 244행 중 230행만 성공했고, 실패한 14행을 직접 하나씩 열어 원인을 진단했다.

실패 유형	원인
오픈 시각 표기 누락	두 번째 "오픈:" 시각에 "시"가 빠지고 "30분"만 있는 경우 (예: "오전 30분")
상대팀명 누락	상대전 괄호 안에 팀명 없이 날짜만 있는 경우 (예: "(9/15)")
더블헤더 복수 표기	날짜 범위("9/29~5")와 복수 상대팀("한화/두산")이 함께 나오는 경우

이 3가지 케이스를 포용하도록 정규식을 보완해 재실행한 결과 244/244행 전부 파싱 성공으로 마무리했다 (단, "한화/두산" 같은 복수 팀 표기 2건은 team_code를 억지로 채우지 않고 빈 값 + 원본 텍스트 그대로 보존 — 잘못된 매핑보다 빈 값이 낫다는 원칙 적용).

정직하게 남겨둔 한계: "예매처:" 뒤에 붙는 채널명+조건 문구는 자유 형식이 너무 다양해서(예: "구단 홈페이지 성인 대상, 구단 홈페이지만 가능" vs "타이거즈 앱 전용 등급별 조건 오픈셜 미확정") 억지로 쪼개지 않고 booking_channel_and_condition 한 컬럼에 통째로 남겼다. 이 필드는 MySQL 정형 조회보다 Chroma 텍스트 검색으로 커버하는 걸 권장한다. 태깅: status=CONFIRMED(파싱 성공), evidence_type=THIRD_PARTY_API.

② 팀코드 매핑 일관성 검증

문제 제기: 이번엔 새로 만든 kbo_standing_crawler.py / kbo_schedule_full_crawler.py / parse_ticket_policy.py가 팀코드를 스크립트 안에 각자 하드코딩해뒀는데, 이게 팀이 만든 공식 매핑표(team_stadium_code_map.csv)와 정말 일치하는지 확인이 안 된 상태였다.

확인 방법: team_stadium_code_map.csv의 10개

team_code(LG/DOOSAN/KIWOOM/SSG/KT/HANWHA/SAMSUNG/KIA/LOTTE/NC)와 9개

stadium_code(JAMSIL/GOCHEOK/MUNHAK/SUWON/DAEJEON/DAEGU/GWANGJU/SAJIK/CHANGWON)를 기준으로 3개

스크립트의 내부 매핑 딕셔너리를 한 줄씩 전수 대조했다. 결과: 3곳 전부 캐노니컬 매핑과 완전히 일치 — 스크립트마다 팀코드가 따로 노는 문제는 없는 것으로 확인.

③ 실행 경로 버그 수정 (자동화 전 필수 선행 작업)

kbo_standing_crawler.py와 kbo_schedule_full_crawler.py 둘 다 저장 경로가 파일명만(예:

"kbo_standing.csv") 하드코딩돼 있어서, scripts 폴더 안에서 실행하면 결과가 원본데이터/신규수집이 아니라 scripts 폴더 안에 새로 생기는 문제가 있었다. 두 스크립트 모두 SCRIPT_DIR(스크립트 자신의 위치) 기준 상대경로로 고쳐서, 실행 위치나 가상환경 위치와 무관하게 항상 올바른 폴더에 저장되도록 수정했다. 수정 후 kbo_standing_crawler.py는 로컬(VS Code, my_venv)에서 실제 실행까지 검증 완료.

남은 일 (우선순위 순)

순서	항목	담당
1	Task Scheduler 자동화 등록 (순위 · 일정 크롤러 2개)	로컬 작업
2	collect_standing_snapshot.py 삭제 (완전 대체됨)	로컬 작업
3	2-9 재입장 규정 검증 질문 3가지를 작성 팀원에게 전달	팀 커뮤니케이션
4	External Places 867건 매점 중복 대조 / 카카오 867건 표본 QA	다음 세션에서 진행 가능
5	2-7 잠실 · 대전 구역 번호 보완 (대전은 한화이글스 공식 앱 확인 유력)	급하지 않음
6	baseball_data 폴더 재구성 (원본데이터/크롤링/전처리/문서)	로컬 작업

자동화 예정 방법 (Windows 작업 스케줄러)

매일 자동으로 갱신돼야 하는 스크립트는 2개다 — kbo_standing_crawler.py(팀 순위 이력 누적)와 kbo_schedule_full_crawler.py(지난 경기 스코어 갱신). 둘 다 경로 버그를 수정했고, 아래 절차대로 Windows 작업 스케줄러에 각각 등록하면 매일 밤 자동으로 데이터가 쌓인다. 예매정책 파서(parse_ticket_policy.py)와 카카오 수집기(collect_kakao_places.py)는 원본 데이터가 자주 바뀌지 않아 자동화 대상에서 제외했다.

공통 준비: baseball_data 루트 기준

작업 스케줄러는 my_venv를 자동으로 활성화하지 않으므로, "프로그램/스크립트" 칸에는 반드시 my_venv 안의 python.exe 전체 경로를 지정해야 한다(그냥 python이라고만 쓰면 시스템 파이썬이 실행되어 pandas가 없을 수 있음). "시작 위치"는 항상 baseball_data 루트 폴더로 지정한다.

① KBO 순위 스냅샷

- 작업 스케줄러 → "기본 작업 만들기" → 이름 "KBO 순위 스냅샷"
- 트리거: 매일, 밤 11시 30분 (그날 경기가 대부분 끝난 뒤)
- 동작 → "프로그램 시작": 프로그램/스크립트 = my_venv\Scripts\python.exe 전체 경로
- 인수 추가: scripts\kbo_standing_crawler.py
- 시작 위치: baseball_data 루트 폴더
- 등록 후 우클릭 → "실행"으로 테스트, kbo_standing_history.csv에 오늘 줄이 늘었는지 확인

② KBO 일정 · 스코어 갱신

- 같은 방식으로 하나 더 등록, 이름 "KBO 일정 스코어 갱신"
- 트리거: 매일, ①보다 5분 뒤(예: 밤 11시 35분) — 같은 API를 동시에 두 번 치지 않도록 살짝 어긋나게
- 인수만 scripts\kbo_schedule_full_crawler.py로 변경, 나머지는 ①과 동일
- 이 스크립트는 시즌 전체(3~10월)를 매번 다시 훑기 때문에 순위 스크립트보다 실행 시간이 더 걸리는 것이 정상
- 테스트 실행 후 kbo_schedule_full.csv가 갱신됐는지 확인

baseball_data 폴더 재구성 계획

파일이 원본데이터/신규수집/scripts 3개 폴더에 뒤섞여 있어, 데이터 흐름 단계 기준(원본데이터 → 크롤링 → 전처리)과 사람이 읽는 문서를 분리하는 4개 폴더 구조로 재정리하기로 했다. 이 세션은 파일 삭제/이동 권한이 없어, 파일 이동은 로컬 파일 탐색기에서 아래 매핑대로 직접 진행한다.

```
baseball_data/
├── 원본데이터/      (그대로 유지 — 팀이 준 원본, 손대지 않는 파일들)
│   ├── 구장먹거리,컨텐츠.xlsx / 구장정보.xlsx / 시트가 뭘 의미하는지.xlsx
│   ├── 재입장 규정.비공식.txt / backlog 보충.xlsx
│   ├── kbo_schedule.csv / kbo_standing.csv / kbo_ticket_policy.csv
│   └──
├── 크롤링/          (API · 웹에서 데이터를 직접 긁어오는 스크립트)
│   ├── kbo_standing_crawler.py / kbo_schedule_full_crawler.py / collect_kakao_places.py
│   └── (collect_standing_snapshot.py는 삭제 대상이라 제외)
│   └──
├── 전처리/          (원본/크롤링 결과를 가공 · 구조화하는 스크립트 + 그 결과물)
│   ├── parse_ticket_policy.py / kbo_schedule_postseason_placeholder.py / team_stadium_map.py
│   ├── team_stadium_code_map.csv (기준 매핑표)
│   ├── kbo_ticket_policy_structured.csv / kbo_schedule_full.csv / kbo_schedule_postseason_tbd.csv
│   ├── kbo_standing_history.csv / 구장정보_좌표추가.xlsx
│   └── 구장반경_외부맛집카페핫플_카카오수집본.xlsx (카카오 크롤링 결과지만 가공된 결과물이라 여기)
│   └──
└── 문서/            (사람이 읽는 문서 + 리서치 결과 엑셀 + 실행 가이드)
    ├── 기초규칙_요약본.md / 원정응원가이드.xlsx / 재입장규정_검증메모.md
    └── 환경설정_my_venv.md / requirements.txt / 진행상황_리포트_20260907.pdf
```

주의: 크롤러 · 파서 스크립트 안에는 SCRIPT_DIR 기준 상대경로(원본데이터, 신규수집을 가리키는 경로)가 들어있어, 폴더 위치가 바뀌면 스크립트를 옮긴 뒤 실행 경로가 여전히 올바른 폴더(원본데이터/전처리)를 가리키는지 재점검이 필요하다. 이동 완료 후 다음 세션에서 경로 재점검 예정.