


KBO 챗봇 데이터 — 크롤링 · 전처리 실행 가이드

2026-09-07 · baseball_data_organized 기준 · 뭘 돌리고, 왜 이렇게 가공했는지 한 장에 정리

진행 상황 한눈에 보기



남은 것

- collect_kakao_places.py — 중복 처리 방향 정하고 실행 (①문제 참고)
- 반입물품 7개 구단 확인 (지금 한화만 공식 확인, 나머지는 사이트 목록만 있음)
- Task Scheduler에 순위 · 일정 크롤러 2개 자동화 등록 (로컬 작업)
- collect_standing_snapshot.py 삭제 (완전히 대체된 옛날 스크립트)
- External Places 867건 카카오톡 QA / 중복 대조 (아직 미착수)

팀원들과 상의할 것

- 카카오톡 반경검색 vs 구단 공식 Food Stores 데이터 — 어떻게 구분/병합할지 결정 필요
- 2-9 재입장 규정.비공식.txt 출처 검증 — 작성한 팀원에게 질문지 전달 필요 (docs/재입장규정_검증메모.md)
- 반입물품 7개 구단 확인 작업 — 누가 나눠서 할지
- 구장정보_좌표추가.xlsx, 구장반경_카카오톡수집본.xlsx 등 예전 산출물을 새 폴더 구조에 맞게 다시 만들지 여부

1. 크롤링 파일 현황

파일	어디서 가져오나	실행	결과 파일
kbo_standing_crawler.py	TVING 순위 API (키 필요없음)	crawling/ 폴더에서 python kbo_standing_crawler.py	data/preprocessed/kbo_standing.csv data/preprocessed/kbo_standing_history.csv
kbo_schedule_full_crawler.py	TVING 일정 API (키 필요없음)	crawling/ 폴더에서 python kbo_schedule_full_crawler.py	data/preprocessed/kbo_schedule_full.csv
collect_kakao_places.py	카카오 로컬 API (.env에 키 있음)	후순위 보류 (아래 사유 참고)	data/preprocessed/stadium_coordinates.csv data/preprocessed/external_places.csv

- 순위 · 일정 크롤러 2개는 실행 완료 — data/preprocessed에 결과 있음
- 예매정책 구조화, 포스트시즌 TBD 생성도 실행 완료
- 실행 전엔 crawling/requirements.txt(pandas, requests, openpyxl) 설치 + my_venv 활성화 필요 → docs/환경설정_my_venv.md 참고

collect_kakao_places.py 보류 이유 — 데이터 중복

문제

- data/raw/구장먹거리,컨텐츠.xlsx에 이미 구단 공식 자료 기준 음식점 284건 + 부가콘텐츠 68건 있음 (OFFICIAL)
- 카카오는 9개 구장 반경으로 음식점 · 카페 · 관광명소를 다시 긁어오는 구조 — 특히 0~60m 이내는 겹칠 가능성 큼 (스크립트 주석에도 있던 우려)
- 같은 장소가 출처 2곳에 다른 이름 · 설명으로 중복되면 챗봇이 같은 곳 두 번 추천하거나 정보가 서로 다를 수 있음

해결 방향 (택 1)

- 카카오 결과에서 구장먹거리,컨텐츠.xlsx와 이름/주소 겹치는 행 자동 제외
- 반경에서 구장 부지 안쪽(0~60m) 빼고 바깥 상권만 수집
- 합치지 않고 "구단 공식" vs "주변 상권(제3자)"으로 구분해서 노출

.env에 API 키는 이미 넣어뒀고 스크립트도 자동으로 읽도록 고쳐놔서, 방향만 정해지면 바로 실행 가능.

2. 자동화 아이디어 — Windows 작업 스케줄러

매일 자동으로 갱신돼야 하는 건 순위 · 일정 크롤러 2개뿐. 예매정책 · 포스트시즌 · 카카오는 원본이 자주 안 바뀌니 자동화 대상에서 제외.

공통 준비

- "프로그램/스크립트"에는 `my_venv\Scripts\python.exe` 전체 경로를 지정 (그냥 `python`이라고만 쓰면 시스템 파이썬이 돌아서 `pandas` 없을 수 있음)
- "시작 위치"는 `baseball_data_organized\crawling` 폴더로 지정 (스크립트가 `../data/...` 상대경로를 쓰기 때문)

① KBO 순위 스냅샷

- 작업 스케줄러 → 기본 작업 만들기 → 이름 "KBO 순위 스냅샷"
- 트리거: 매일, 밤 11시 30분 (그날 경기 대부분 끝난 뒤)
- 인수: `kbo_standing_crawler.py`
- 등록 후 우클릭 → 실행으로 테스트 → `data/preprocessed/kbo_standing_history.csv`에 오늘 줄 늘었는지 확인

② KBO 일정 · 스코어 갱신

- 같은 방식으로 하나 더, 이름 "KBO 일정 스코어 갱신"
- 트리거: 매일, ①보다 5분 뒤(11시 35분) — 같은 API 서버를 동시에 두 번 안 치게 살짝 어긋나게
- 인수: `kbo_schedule_full_crawler.py` (3~10월 전체를 매번 다시 훑어서 ①보다 오래 걸리는 게 정상)
- 테스트 실행 후 `data/preprocessed/kbo_schedule_full.csv` 갱신했는지 확인

두 작업 다 등록만 하면 이후로는 로컬 PC가 켜져 있는 한 사람이 직접 안 돌려도 매일 자동으로 실행.

3. 전처리 스크립트별 요약

파일마다 "어디서 왔고 → 무슨 규칙으로 바꿨는지"만 짧게. 자세한 코드는 preprocessing/ 폴더 참고.

① kbo_standing_history.csv

출처

- kbo_standing.csv와 같은 TVING 순위 API
- 원본엔 안 쓰던 필드도 추가로 뽑음: 연승/연패, 팀타율, 방어율, 최근 10경기

규칙

- kbo_standing.csv(최신 1개, 매번 덮어쓰는) 그대로 두고 → 별도 파일에 날짜(snapshot_date) 붙여서 매일 쌓음
- 오늘 날짜가 이미 있으면 중복 저장 안 함 (하루 여러 번 돌려도 안전)
- 팀명은 team_stadium_code_map.csv 기준 코드로 통일

태그: THIRD_PARTY_API / CONFIRMED

② kbo_schedule_full.csv

출처

- kbo_schedule.csv와 같은 TVING 일정 API
- 원래는 "이번 달 남은 경기"만 나왔음 → 개막일(3/28)부터 오늘까지 지난 경기 + 앞으로 남은 경기까지 3~10월 전체로 확장

규칙

- 올스타전, 시범경기(3/12~3/24)는 순위에 안 들어가니 자동 제외
- 끝난 경기는 스코어까지 content에 포함, 팀명/구장명은 표준 코드로 매핑
- 포스트시즌은 API에 아직 없음(순위 확정 전) → ③번 스크립트가 따로 처리

태그: THIRD_PARTY_API / CONFIRMED

③ kbo_schedule_postseason_tbd.csv

출처

- 나무위키 2026 KBO 포스트시즌 문서 + KBO 공식 일정 발표(2025-12-19)
- 실시간 크롤링 아님 — 이미 발표된 라운드 날짜·대진 규칙을 스크립트에 고정해둔 것

규칙

- 와일드카드/준PO/PO/한국시리즈 4행 생성, 참가팀은 전부 "TBD"
- 일정 바뀌면 스크립트 안 ROUNDS만 수정, 팀 확정되면 이 스크립트 다시 쓰지 말고 수동으로 채우기

태그: DERIVED / OPEN (확정 아니니 리트리버가 사실처럼 답 안 하게 구분)

④ kbo_ticket_policy_structured.csv

출처

- data/raw/kbo_ticket_policy.csv (yagu.today 크롤링, 244행)
- 원본은 문장 하나에 다 뭉쳐 있음: "[선예매] 두산 (베어스클럽) 9월5일 오전10시 (9/12 NC전)...예매처:..."

규칙

- 정규식으로 정책유형·정책명·오픈일시·상대팀·최대매수·예매처를 컬럼별로 분리
- 예매처 뒤 채널+조건 문구는 형식이 너무 제각각이라 안 쪼개고 한 컬럼에 원문 그대로 보존
- 매칭 안 되는 행은 버리지 않고 FAILED로 표시, 원본은 남김 (현재 244/244 전부 성공)

태그: THIRD_PARTY_API / CONFIRMED

⑤ team_stadium_map.py / team_stadium_code_map.csv

출처

- 팀이 준 data/raw/구장정보.xlsx 기준 (별도 크롤링 아님)

규칙

- 한글 축약형(두산/기아 등) ↔ 영문 표준코드(DOOSAN/KIA 등) 양방향 변환표
- kbo_schedule.csv처럼 팀명이 붙어 나오는 경우("KTKIA")는 문장에서 정규식으로 재추출

- ①②④ 스크립트 내부 매핑을 이 표와 한 줄씩 대조 완료 — 10개 팀 코드 전부 일치

태그: OFFICIAL / CONFIRMED

4. 데이터 출처 한눈에 보기

OFFICIAL=구단/리그 공식 · THIRD_PARTY_API=공개 API(비공식이지만 실제 경기결과 반영) · DERIVED=공식 발표 기반으로 만들 · UNOFFICIAL=커뮤니티/블로그

파일	출처	등급
kbo_standing.csv / kbo_standing_history.csv	TVING 순위 API	THIRD_PARTY_API
kbo_schedule.csv / kbo_schedule_full.csv	TVING 일정 API	THIRD_PARTY_API
kbo_schedule_postseason_tbd.csv	나무위키 + KBO 공식 일정 발표	DERIVED
kbo_ticket_policy.csv / _structured.csv	yagu.today 크롤링	THIRD_PARTY_API
구장정보.xlsx / team_stadium_code_map.csv	팀 원본 조사 자료	OFFICIAL
구장먹거리,컨텐츠.xlsx (Food Stores/Attractions)	구단 · 운영사 공식 자료	OFFICIAL
stadium_coordinates.csv / external_places.csv	카카오 로컬 API (보류 중)	THIRD_PARTY_API
원정응원가이드.xlsx	나무위키 · 구단사이트 · 블로그 · 커뮤니티 교차확인	UNOFFICIAL
기초규칙_요약본.md	자체 작성 + 웹 검색으로 공식 규정 확인	DERIVED/OFFICIAL 혼합
반입물품_구단별정리.md	KBO 공식 캠페인 + 블로그 + 구단 공식 사이트(일부 확인 전)	UNOFFICIAL/OPEN 혼합

5. 데이터 자료 문서 구조도

지금까지 만든 파일 전체를 폴더 구조로 정리한 것. 데이터는 "손냈는지 여부"로 raw/preprocessed를 나누고, 스크립트는 "수집이나 가공이나"로 crawling/preprocessing을 나눴다.

```
baseball_data_organized/
├── data/
│   ├── raw/      (팀 원본, 손 안 댄)
│   │   ├── 구장정보.xlsx · 구장먹거리,컨텐츠.xlsx · 시트가 뭘 의미하는지.xlsx
│   │   ├── 재입장 규정.비공식.txt · backlog 보충.xlsx
│   │   ├── kbo_schedule.csv · kbo_ticket_policy.csv
│   │   └── team_stadium_code_map.csv (기준 매핑표)
│   └── preprocessed/ (크롤링·전처리 결과물, 실행할 때마다 갱신)
│       ├── kbo_standing.csv · kbo_standing_history.csv
│       ├── kbo_schedule_full.csv · kbo_schedule_postseason_tbd.csv
│       ├── kbo_ticket_policy_structured.csv
│       └── stadium_coordinates.csv · external_places.csv ← 보류(중복 이슈)
├── crawling/      (수집 스크립트, 결과물 없음)
│   ├── kbo_standing_crawler.py · kbo_schedule_full_crawler.py
│   └── collect_kakao_places.py (.env 자동 로드하도록 수정함) · requirements.txt
├── preprocessing/ (가공 스크립트, 결과물 없음)
│   ├── parse_ticket_policy.py · kbo_schedule_postseason_placeholder.py · team_stadium_map.py
└── docs/          (사람이 읽는 문서)
    ├── 기초규칙_요약본.md · 원정응원가이드.xlsx · 반입물품_구단별정리.md
    ├── 재입장규정_검증메모.md · 환경설정_my_venv.md
    └── 진행상황_리포트_20260907.pdf · 크롤링_전처리_실행가이드_20260907.pdf
```

데이터 흐름

- data/raw → (crawling 스크립트 실행) → data/preprocessed 예) kbo_standing.csv → kbo_standing_history.csv
 - data/raw → (preprocessing 스크립트 실행) → data/preprocessed 예) kbo_ticket_policy.csv → _structured.csv
 - data/raw끼리는 서로 영향 없음 — 팀이 준 원본은 그대로 보존
- ※ kbo_standing.csv는 얼핏 원본 같지만 실행할 때마다 덮어써지는 생성물이라 preprocessed에 둬.